

项目报告：政策法规问答助手（RAG 领域 AI 助理）

版本：2026-07（基于当前代码与知识库状态整理） 定位：某 NLP 课程期末大作业（RAG 主线）；本报告同时给出「从 Demo 走向企业级产品」的演进路线。
声明：本系统回答仅供学习参考，不构成法律或行政意见。

1. 项目背景与选题

- 选题：政策法规问答助手——面向公开政策、法规条文、政务服务办事指南的垂直领域 RAG 问答系统。
- 背景痛点：通用大模型在政策法规领域存在知识过时、引用不清、易幻觉等问题；RAG 通过外挂权威知识库，使回答可溯源、可验证、可拒答。
- 合规约束：高风险领域仅作学习参考；回答须标注「仅供学习参考，不构成法律意见」并尽量给出法条来源。

2. 系统现状（Current State）

2.1 技术栈

模块	选用	说明
后端框架	FastAPI + uvicorn	SSE 流式接口，并静态托管前端，无独立前端服务器
前端	原生 HTML/CSS/JS（模块化）	apiService / ragUI / messageHandler / documentManager / emojiManager / themeManager / config
向量库	ChromaDB（本地持久化）	持久化目录 backend/vector_db, 当前 3953 个片段
嵌入模型	ChromaDB 内置 all-MiniLM-L6-v2	检索路径直接使用 Chroma 默认嵌入函数，无需运行时下载 sentence-transformers
大模型	DeepSeek API（OpenAI 兼容）	通过 config.config 配置，回答 temperature=0
RAG 框架	自研混合检索（services/）	向量 + 条文号关键字 + 通用锚点，文章级切分

2.2 知识库

- 规模：data/raw/ 下 21 篇公开合规文档（含 18 部法律全文 + 3 篇办事指南），来源见 data/SOURCES.md。
- 构建：python backend/ingest.py 加载 → 文章级切分（单条 ≤300 字，契合 MiniLM ~256 token 窗口）→ 灌入 ChromaDB。
- 可复现：入库为确定性流程，支持运行时通过上传接口增量追加。

2.3 系统架构

flowchart LR U[用户] --> FE[前端聊天界面] FE --> SSE[JSONL API/FastAPI /api/chat/stream] API --> RAG[RAGService] RAG --> HYB[混合召回: 向量+条文号+锚点] HYB --> VS[(ChromaDB 3953 片段)] VS --> ADAPT[自适应筛选 + 阈值判定] ADAPT --> REF[拒答模板] ADAPT --> LLM[DeepSeek] LLM --> FE FE --> use_rag=false LLM2[纯大模型对比]

2.4 核心机制

- 文章级切分：按「第X条」切分，保证单条法条语义完整、不被相邻法条稀释。
- 混合检索：
 - 向量召回（候选池 12，自适应保留 ≤ 8 块，系数 1.8）；
 - 条文号定位：阿拉伯/中文数字归一化后子串匹配，强制顶起对应法条；
 - 通用锚点：抽取 3-4 字中文 n-gram 作为强锚点，匹配规则为「 ≥ 1 个强锚点 或 ≥ 2 个弱锚点」，精准召回「股东会职权」「正当防卫」类易混淆查询，同时排除「今天北京天气」等离题查询。
- 无依据拒答：硬阈值 $RELEVANCE\ THRESHOLD=0.72 +$ 提示词兜底，知识库无可靠依据时明确拒答、不调用大模型、不编造。
- 流式带引用输出：POST /api/chat/stream 以 JSONL 流式返回，每块携带 `sources:[{content,source,score,chunk_id}]`，前端以 [n] 标注引用并折叠展示来源卡片。
- RAG / LLM-only 对比开关：请求 `use_rag` 字段切换纯大模型模式，用于对照实验。

2.5 前端能力

聊天界面、来源引用卡片、文档管理（上传/清空/统计）、主题切换、表情、对话历史；后端同时提供 `documents/upload`、`documents/count`、`documents/clear`、`health` 等接口。

3. 评测结果 (Evaluation)

采用 LLM-as-judge（裁判模型 DeepSeek）对 53 题评测集（25 事实型 / 16 综合型 / 12 无答案型）自动评分，维度与 Ragas 对齐；并逐题对比 RAG 与 LLM-only 回答。完整结果见 `tests/results_scored.md`，失败分析见 `tests/failure_analysis.md`。

说明：原计划用 Ragas 多指标编排，但其每个指标多次调用大模型，在 DeepSeek 作为裁判时单题即超时（ $> 5\text{ min}$ ），故改为单次调用返回多维度评分，稳定且等价。

3.1 评分汇总

维度	总体	事实型	综合型	无答案型
忠实度（无幻觉）	4.93	5.0	4.75	5.0
相关性	4.81	4.96	4.44	5.0
上下文精确率	3.42	4.48	3.50	1.08*
上下文召回	3.45	4.48	3.38	1.42*
事实正确性	4.72	4.72	—	—
事实型来源召回率	—	1.0	—	—
无答案型拒答率	—	—	—	1.0

* 无答案型精确率/召回偏低为预期（恰当拒答、无相关上下文）。

3.2 RAG vs LLM-only 对比

指标	RAG（检索增强）	LLM-only（纯大模型）
总题数	53	53
给出回答	32	53
直接拒答	21	0

指标	RAG (检索增强)	LLM-only (纯大模型)
事实型来源召回率	1.0	—

RAG 在「知识库无依据」问题上以拒答避免幻觉（忠实度近满分）；LLM-only 不检索，对超纲问题易凭参数记忆编造——印证了 RAG 在可信性上的核心价值。

3.3 主要短板（已记录于 failure_analysis.md）

1. 保守拒答：约 20%
的部分覆盖问题被误拒（如「未成年人网络欺凌」「处理个人信息原则」），根因为具体条文未被顶入候选，模型依据不足而拒。
2. 检索精度/召回中等（3.4 左右）：无重排（rerank）、单一向量召回、无查询改写。
3. 知识库规模有限（21 篇）：部分组合/场景问题缺乏对应条文。
4. 工程化缺失：无鉴权、多租户、审计、CI、可观测性；依赖手动评测。

4. 从 Demo 走向企业级产品的演进路线

当前系统是一个功能完整的课程 Demo。要成为可投入企业使用的产品，需在「检索质量、答案可信、知识库运营、工程化、合规」五个层面系统升级。

4.1 检索质量 (Retrieval)

- 引入重排 (Reranker)：向量召回后用 Cross-Encoder 对 Top-K 重排，显著提升精确率/召回（当前最大短板）。
- 稠密 + 稀疏混合：dense vector + BM25/稀疏向量融合，兼顾语义与关键词（法律术语、条文号）。
- 查询理解：查询改写、问题分解（多跳）、实体/法名识别，把「未成年人网络欺凌」映射到「未成年人保护法·网络保护章」。
- 元数据过滤：按效力层级、地域、时效过滤，避免引用已废止条文。
- 更大更干净的知识库：多格式解析（docx/pdf/扫描件 OCR）、去重、版本化。

4.2 答案可信与安全性 (Trust & Safety)

- 分级拒答：以置信度而非硬阈值决定「直接拒答 / 弱回答+提示 / 正常回答」，减少生硬拒答。
- 引用归因 (Attribution)：逐句标注出处片段，支持点击溯源；对无法归因的陈述显式标注「模型补充，非库内依据」。
- 幻觉护栏：输出后校验是否与检索片段一致 (NLI/自洽)，高风险回答强制人工复核入口。
- 模型策略：关键场景可换更强/私有化模型，或对领域数据做微调；对回答做事实一致性约束。

4.3 知识库运营 (KB Ops)

- ** ingestion pipeline**：可视化入库、格式解析、按文档类型选择切分策略、去重与冲突检测。
- 来源治理：保留出处链接与发布/生效日期，支持「条文更新」自动失效旧片段。
- 人在回路 (Human-in-the-loop)：用户纠错、专家标注、错误回流至评测集与知识库。

4.4 工程化 (Productionization)

- 鉴权与多租户：登录、RBAC、租户隔离；敏感操作审计日志；PII 脱敏。
- 可观测性与成本：链路追踪 (LangSmith/OpenTelemetry)、延迟/令牌/拒答率监控、用量与成本看板。
- 部署与弹性：容器化、水平扩展、向量库托管（如云向量数据库）、模型网关与降级。
- 评测进 CI：把 53 题（及扩充集）作为回归测试，每次变更自动跑分，防止质量回退。
- 反馈闭环：用户点赞/点踩、对话评价回灌，形成持续评估。

4.5 合规与信任 (Compliance)

- 回答强制免责声明与来源链接；法律文本版本化；对高风险的「行政处罚/诉讼/合同」类给出「建议咨询专业律师」升级路径。
- 数据合规：知识库版权与个人信息处理符合相关法规；访问与留痕可审计。

4.6 建议路线图（分阶段）

阶段	目标	关键动作
P0（加固）	提升可信与可用性	Reranker + 查询改写 + 分级拒答 + 补库覆盖缺口
P1（产品化）	可内部试用	鉴权/审计、可观测性、评测进 CI、反馈闭环
P2（企业级）	多租户对外服务	多租户隔离、私有化/云向量库、SLA 监控、合规审查
P3（智能化）	持续进化	人在回路知识运营、领域微调、主动更新与告警

5. 结论

当前系统已具备完整的 RAG 问答能力：混合检索、文章级切分、来源引用、无依据拒答，并在 53 题自动评测中取得忠实度 4.93、事实正确性 4.72、无答案拒答率 100% 的结果，验证了「外挂知识库提升回答可信性」的核心假设。其主要短板（保守拒答、检索精度、工程化缺失）恰是通向企业级产品的明确演进方向。按 P0→P3 路线图迭代，可逐步从课程 Demo 发展为可投入企业使用的政策法规智能助理。